

社交网络影响最大化的种子节点选择策略分析：基于组合优化的视角

郑墨涵^{1,2}

- (1. 西安电子科技大学 计算机科学与技术学院, 陕西 西安 710071;
2. 西安电子科技大学 网络与信息安全学院, 陕西 西安 710071)

摘要：社交网络影响最大化是社交网络分析与营销中的核心问题，旨在选择最具有影响力的种子节点集合以实现信息传播范围的最大化。尽管该问题的贪心算法因其近似比保证而被广泛使用，但其背后的组合数学理论基础仍有深入探索的空间。本文从组合优化的理论视角，对影响最大化问题的种子节点选择策略进行系统性分析。首先，通过严格的组合推导，证明了在独立级联模型和线性阈值模型下，影响传播函数的单调子模性，并分析了模型参数变化对子模性的影响。其次，针对特殊图结构（树、有界树宽图、无标度网络），提出了基于图分解的精确算法或改进的近似算法，并分析了算法复杂度与近似比。进一步，从组合集合论的角度定义了种子集合的鲁棒性度量，分析了种子集合对网络结构扰动的稳定性。理论分析表明，在树结构上，影响最大化问题存在多项式时间精确算法；在一般图上，贪心算法的近似比紧界为 $(1-1/e)$ 。仿真实验在真实社交网络数据集上进行，验证了理论分析结果，并展示了不同图结构对算法性能的影响。本研究深化了对影响最大化问题组合性质的理解，为设计更高效的传播策略提供了理论依据。

关键词：社交网络；影响最大化；子模函数；组合优化；图算法；鲁棒性分析

中图分类号：TP391 文献标识码：A 文章编号：1001-2400(2XXX)0X-0-0

Analysis of Seed Node Selection Strategies for Social Network Influence Maximization: A Combinatorial Optimization Perspective

ZHENG Mohan^{1,2}

- (1. School of Computer Science and Technology, Xidian University, Xi'an 710071, China;
2. School of Cyber Engineering, Xidian University, Xi'an 710071, China)

Abstract: Influence maximization in social networks is a core problem in social network analysis and marketing, aiming to select a set of seed nodes that maximize the spread of information. Although the greedy algorithm is widely used due to its approximation guarantee, the combinatorial mathematical foundations behind it deserve further exploration. This paper provides a systematic analysis of seed node selection strategies for influence maximization from a theoretical perspective of combinatorial optimization. Firstly, through rigorous combinatorial derivations, we prove the monotone

收稿日期：

网络出版时间：

基金项目：

作者简介：郑墨涵（2005—），男，西安电子科技大学本科生，E-mail: ×××××@xidian.edu.cn

通信作者：郑墨涵（2005—），男，学生，E-mail: ×××××@mail.xidian.edu.cn

网络出版地址：

submodularity of the influence spread function under both the Independent Cascade and Linear Threshold models, and analyze the impact of model parameter variations on submodularity. Secondly, for special graph structures (trees, bounded-treewidth graphs, scale-free networks), we propose exact algorithms based on graph decomposition or improved approximation algorithms, and analyze their complexity and approximation ratios. Furthermore, from a combinatorial set theory perspective, we define robustness metrics for seed sets and analyze their stability under perturbations of network structure. Theoretical analysis shows that on tree structures, the influence maximization problem admits a polynomial-time exact algorithm; on general graphs, the tight approximation ratio of the greedy algorithm is $(1-1/e)$. Simulation experiments on real social network datasets validate the theoretical findings and demonstrate the impact of different graph structures on algorithm performance. This research deepens the understanding of the combinatorial properties of the influence maximization problem and provides a theoretical foundation for designing more efficient propagation strategies.

Key Words: social networks; influence maximization; submodular function; combinatorial optimization; graph algorithms; robustness analysis

1 引言

随着在线社交网络的蓬勃发展,信息、观点和行为模式的传播现象引起了学术界和工业界的广泛关注。社交网络影响最大化问题旨在从网络中选择一个固定大小的初始用户集合(称为种子节点),通过某种传播模型(如独立级联模型、线性阈值模型)的扩散,使得最终被影响的用户数量期望值最大化。该问题在病毒式营销、谣言控制、公共卫生干预等领域具有重要应用价值。

Kempe 等人于 2003 年首次将影响最大化问题形式化为一个组合优化问题,并证明了在独立级联模型和线性阈值模型下,影响传播函数是单调子模的^[1]。基于这一性质,他们提出了一个简单的贪心算法(迭代地选择边际收益最大的节点),该算法能够达到 $(1-1/e-\epsilon)$ 的近似比。这一开创性工作奠定了该问题的理论基础,并引发了持续至今的研究热潮。

然而,现有研究大多集中于开发更高效的启发式算法或处理大规模网络的工程实现,对问题本身组合性质的深入理论分析相对缺乏。具体而言,以下几个关键理论问题尚未得到充分解答:(1) 传播模型的假设条件如何精确地导致子模性?模型参数的扰动是否会破坏子模性?(2) 在具有特殊拓扑结构的网络上(如树、有界树宽图、无标度网络),问题是否具有更好的算法可解性?(3) 所选种子集合对网络结构的小幅扰动是否具有鲁棒性?这种鲁棒性如何用组合数学的语言刻画?

本文旨在从组合优化的理论视角,对影响最大化问题的种子节点选择策略进行系统性分析。我们不仅重新审视和严格证明了经典模型下的子模性,还探讨了子模性成立的边界条件。针对特殊图结构,我们设计了相应的精确或近似算法,并分析了其性能保证。此外,我们首次从组合集合论的角度定义了种子集合的鲁棒性,并分析了其性质。这些理论分析不仅加深了对影响最大化问题本质的理解,也为设计更稳健、高效的传播策略提供了新的思路。

本文的结构如下:第 2 节给出问题定义与传播模型的形式化描述;第 3 节进行子模性的严格证明与深入分析;第 4 节针对特殊图结构设计算法并分析性能;第 5 节提出鲁棒性度量并进行理论分析;第 6 节通过仿真实验验证理论结果;第 7 节总结全文并展望未来工作。

2 问题定义与模型

2.1 社交网络模型

设社交网络为一个有向图 $G=(V, E)$, 其中 V 是节点集合, $|V|=n$, 每个节点代表一个用户; E 是边集合, 每条有向边 $(u, v) \in E$ 表示用户 u 可能影响用户 v 。每条边 (u, v) 附带一个权重 $p_{uv} \in [0, 1]$, 表示 u 成功激活 v 的概率 (在独立级联模型中) 或 u 对 v 的影响权重 (在线性阈值模型中)。

2.2 传播模型

定义 1 (独立级联模型, IC). 在 IC 模型中, 每个节点有两种状态: 活跃和非活跃。过程从初始种子集合 $S \subseteq V$ 中的节点被激活开始, 在离散时间步中展开。在时间 t , 每个在时间 $t-1$ 新激活的节点 u 对每个尚未激活的出邻居 v 以概率 p_{uv} 尝试激活。无论尝试成功与否, u 在后续步骤中不再进行激活尝试。如果一个节点在同一时间步被多个邻居尝试激活, 这些尝试的顺序任意, 但只要有一次成功, 该节点即变为活跃。过程直到没有新的节点被激活时停止。

定义 2 (线性阈值模型, LT). 在 LT 模型中, 每个节点 v 有一个随机阈值 $\theta_v \in [0, 1]$, 均匀随机采样。每个节点 v 受其入邻居的影响, 满足 $\sum_{u \in N_{in}(v)} p_{uv} \leq 1$, 其中 $N_{in}(v)$ 是 v 的入邻居集合。过程从种子集合 S 激活开始。在任意时间步, 如果一个非活跃节点 v 的活跃入邻居的影响权重之和达到或超过其阈值, 即 $\sum_{u \in N_{in}(v) \text{ 且 } u \text{ 活跃}} p_{uv} \geq \theta_v$, 则 v 被激活。过程直到没有新的节点被激活时停止。

2.3 影响最大化问题

设 $\sigma(S)$ 表示从种子集合 S 开始, 按照给定传播模型 (IC 或 LT) 最终活跃节点数量的期望值。函数 $\sigma: 2^V \rightarrow \mathbb{R}^+$ 称为影响传播函数。

问题 (影响最大化). 给定一个有向图 $G=(V, E)$, 传播模型 (IC 或 LT), 以及一个正整数 k , 找到一个种子集合 $S \subseteq V$, $|S|=k$, 使得 $\sigma(S)$ 最大化。即:

$$S^* = \arg \max_{S \subseteq V, |S|=k} \sigma(S).$$

该问题在一般图上被证明是 NP 难的。

3 子模性分析与组合优化基础

3.1 子模函数定义与性质

定义 3 (子模函数). 设 U 是一个有限集, 函数 $f: 2^U \rightarrow \mathbb{R}$ 是子模的, 如果对于任意 $A \subseteq B \subseteq U$ 和任意 $x \in U \setminus B$, 满足:

$$f(A \cup \{x\}) - f(A) \geq f(B \cup \{x\}) - f(B).$$

直观上, 子模性刻画了边际收益递减的性质。若 f 还满足 $f(\emptyset)=0$ 且对于任意 $A \subseteq B$ 有 $f(A) \leq f(B)$, 则称 f 是单调非减的。

定理 1 (Nemhauser et al., 1978). 对于单调非减子模函数 f 和规模约束 k , 贪心算法 (迭代选择边际增益最大的元素) 返回的集合 S_{greedy} 满足:

$$f(S_{\text{greedy}}) \geq (1 - 1/e) \cdot f(S^*).$$

其中 S^* 是最优解。该近似比是紧的^[2]。

3.2 IC 模型下子模性的证明

IC 模型下的传播过程可以等价地由“活边”模型描述: 每条边 (u, v) 以概率 $p \sim uv \sim$ 被标记为“活边”, 否则为“死边”。这些标记独立进行。然后, $\sigma(S)$ 等于从 S 出发通过活边可达的节点数量的期望值。

引理 1. 在 IC 模型中, 对于任意固定的活边标记结果, 从 S 出发可达的节点集合 $R(S)$ 满足: 对于任意 $A \subseteq B \subseteq V$ 和 $v \in V \setminus B$, 有

$$R(A \cup \{v\}) \setminus R(A) \supseteq R(B \cup \{v\}) \setminus R(B).$$

证明: 固定活边标记后, $R(S)$ 是从 S 出发通过活边可达的节点集合。由于图是固定的, $R(\cdot)$ 是单调的。若一个节点 w 属于 $R(B \cup \{v\}) \setminus R(B)$, 则存在一条从 v 到 w 的活边路径, 且该路径不经过 B 中的节点。那么显然 w 也属于 $R(A \cup \{v\})$, 因为 $A \subseteq B$, 该路径也不经过 A 中的节点。因此, $R(B \cup \{v\}) \setminus R(B) \subseteq R(A \cup \{v\}) \setminus R(A)$ 。取基数即得边际增益的递减性。

定理 2. IC 模型下的影响传播函数 $\sigma(\cdot)$ 是单调非减子模函数。

证明: 由引理 1, 对于每一个活边标记的实例, 指示函数 $I\{w \in R(\cdot)\}$ 是子模的。因为子模函数的非负线性组合仍然是子模的, 所以 $\sigma(S) = \sum\{w \in V\} P(w \in R(S))$ 也是子模的。单调性显然。

3.3 LT 模型下子模性的证明

LT 模型的分析较为复杂。我们采用 Kempe 等人的证明思路, 将 LT 过程转化为等价的“活边”过程: 每个节点 v 随机选择一个入边, 选择边 (u, v) 的概率为 $p \sim uv \sim$, 或不选择任何边 (概率为 $1 - \sum\{u \in N \sim in \sim (v)\} p \sim uv \sim$)。如果选择了边 (u, v) , 则称 (u, v) 是 v 的活入边。然后, $\sigma(S)$ 等于从 S 出发沿着活入边反向可达的节点集合的期望大小。即, w 能被 S 激活当且仅当存在一条从 w 到 S 中某个节点的路径, 其中每条边都是活入边。

引理 2. 在 LT 模型中, 对于固定的每个节点的活入边选择结果, 从 S 出发反向可达的节点集合 $R \sim LT \sim (S)$ 满足: 对于任意 $A \subseteq B \subseteq V$ 和 $v \in V \setminus B$, 有

$$R_{LT}(A \cup \{v\}) \setminus R_{LT}(A) \supseteq R_{LT}(B \cup \{v\}) \setminus R_{LT}(B).$$

证明: 与 IC 模型类似, 固定活入边选择后, $R \sim LT \sim (\cdot)$ 是单调的。若 $w \in R \sim LT \sim (B \cup \{v\}) \setminus R \sim LT \sim (B)$, 则存在一条从 w 到 v 的活入边路径, 且该路径不经过 B 中的节点。那么该路径显然也不经过 A 中的节点, 因此 $w \in R \sim LT \sim (A \cup \{v\})$ 。边际收益递减得证。

定理 3. LT 模型下的影响传播函数 $\sigma(\cdot)$ 是单调非减子模函数。

证明: 同定理 2, 由引理 2 和期望的线性性质可得。

3.4 模型参数扰动对子模性的影响

上述证明依赖于模型的特定假设。若模型发生改变, 子模性可能不再成立。考虑以下两种扩展模型:

IC-N 模型 (节点相关概率): 激活概率 $p \sim uv \sim$ 可能依赖于尝试激活的节点集合 (例如, 协同效应)。此时, 子模性不一定成立。

LT 模型权重和不等 1: 若节点 v 的入边权重之和大于 1, 需重新定义阈值过程。一种常见做法是将权重归一化。但若使用非归一化权重且阈值范围相应调整, 子模性证明可能失效。

我们通过构造反例说明子模性可能被破坏。例如，在 IC-N 模型中，假设两个节点同时尝试激活一个共同邻居时，成功概率大于各自单独尝试的概率之和，这可能导致边际收益递增，从而破坏子模性。

命题 1. 在 IC 和 LT 的标准定义下，子模性成立。但若放松模型假设（如引入协同效应或非归一化权重），子模性不能保证，贪心算法的近似比也不再成立。

4 基于图结构特性的算法设计与分析

影响最大化在一般图上是 NP 难的，但在某些特殊图结构上可能存在精确多项式算法或更好的近似算法。

4.1 树结构上的精确算法

定理 4. 在树结构（有向树，边指向子节点）上，IC 和 LT 模型的影响最大化问题存在多项式时间精确算法。

证明思路：以 IC 模型为例。由于树无环，从种子集合 S 开始的传播过程是确定的：每个节点被激活当且仅当其父节点被激活且连接边为“活边”。但边是否存活是随机的。我们可以使用动态规划自底向上计算期望影响。

算法描述：

将树视为以任意节点为根的有根树。

对于每个节点 v ，定义 $f(v, i)$ 表示在以 v 为根的子树中，选择 i 个种子节点（可以包括 v 本身）所能获得的最大期望影响值（仅统计子树内节点）。

递归计算：若 v 是叶子，则 $f(v, 0)=0, f(v, 1)=1$ （激活自己）。

对于非叶子节点 v ，先合并其各子节点的动态规划表，得到在子树的节点中选择一定数量种子的最大影响（不考虑 v 的影响）。然后考虑是否选择 v 作为种子：若选择 v ，则 v 以概率 p_{vc} 激活每个子节点 c ，进而影响子树。通过组合子问题的解，可以计算 $f(v, i)$ 。

最终根节点的 $f(\text{root}, k)$ 即为答案。

该动态规划的状态数为 $O(nk)$ ，转移需要组合子节点，总复杂度为 $O(nk^2)$ 。对于 LT 模型，由于阈值模型在树上的确定性（给定种子集合，激活过程确定），也可以设计类似的动态规划。

4.2 有界树宽图上的算法

树宽是衡量图与树相似程度的参数。许多 NP 难问题在树宽有界图上有多项式时间算法。

定义 4 (树分解与树宽). 图 $G=(V, E)$ 的树分解是一个树 T ，每个节点 X_i （称为袋）是 V 的子集，满足：(1) $\cup X_i = V$ ；(2) 对于每条边 $(u, v) \in E$ ，存在某个袋 X_i 包含 u 和 v ；(3) 对于每个节点 $v \in V$ ，包含 v 的袋形成的 T 的子树是连通的。树宽定义为 $\max_i |X_i| - 1$ 的最小值。

定理 5. 对于树宽为 tw 的图，IC 模型的影响最大化问题可以在时间 $n^{O(tw)}$ 内精确求解。

证明思路：利用树分解，设计基于袋的动态规划。状态需要记录袋中每个节点的状态（是否种子、是否被激活等）。由于树宽有界，袋的大小为 $tw + 1$ ，状态数为指数于 tw ，但多项式于 n 。通过树分解树上递归计算，可以求得精确解。然而，该方法是指数时间依赖树宽，仅适用于树宽较小的图。

4.3 无标度网络上的近似算法改进分析

无标度网络具有度分布服从幂律的特性，存在少量高度节点（枢纽）。直观上，选择高度节点作为种子可能获得良好效果。

启发式算法：度折扣启发式（DegreeDiscount）在无标度网络上表现接近贪心算法^[3,5]，但运行更快。

理论分析：在无标度网络生成模型（如 Barabási-Albert 模型）下，可以分析贪心算法的性能。有研究表明，由于枢纽节点的存在，贪心算法的解与最优解的差距可能小于最坏情况下的 $(1-1/e)$ 界。我们通过以下命题描述：

命题 2. 在 Barabási-Albert 模型生成的无标度网络中，当 k 较小时，贪心算法选择的种子大多为高度节点，且这些节点的影响范围近似不重叠。此时，贪心算法的近似比可能接近 1。

5 种子集合的鲁棒性分析

5.1 鲁棒性定义

社交网络结构可能随时间变化或存在观测误差。我们希望所选种子集合 S 在面对网络结构的小幅扰动时，其影响传播效果 $\sigma_{G'}(S)$ 不会显著下降。

设 $G=(V, E)$ 为原网络， $G'=(V, E')$ 为扰动后的网络（例如，添加或删除少量边）。定义 $\Delta(G, G')$ 为扰动度量，如对称差 $|E \Delta E'|$ 。

定义 5 (鲁棒性). 给定种子集合 S 和扰动上界 δ ，定义 S 的鲁棒性 $\rho(S, \delta)$ 为在最坏扰动 G' （满足 $\Delta(G, G') \leq \delta$ ）下，影响传播的相对损失的下界：

$$\rho(S, \delta) = \min_{G': \Delta(G, G') \leq \delta} \frac{\sigma_{G'}(S)}{\sigma_G(S)}.$$

若 $\rho(S, \delta)$ 接近 1，则称 S 对 δ -扰动是鲁棒的。

5.2 基于影响路径的组合分析

影响传播依赖于从种子到其他节点的路径。扰动可能破坏关键路径。

定义 6 (关键边). 对于种子集合 S 和节点 v ，一条从 S 到 v 的路径 P 称为关键的，如果 P 上的边在传播过程中被标记为活边（或活入边）的概率较高，且没有其他冗余路径。若 P 上的边被删除，则 v 被激活的概率大幅下降。

鲁棒性强的种子集合应使影响传播不依赖于少数关键边，即对每个目标节点，存在多条独立的影响路径。

定理 6. 在 IC 模型中，若种子集合 S 满足：对于每个节点 v ，存在至少 r 条从 S 到 v 的边不相交路径，且每条路径的激活概率乘积至少为 α ，则对于任意删除至多 δ 条边的扰动（ $\delta < r$ ），有

$$\rho(S, \delta) \geq 1 - \frac{\delta}{r} \cdot (1 - \alpha).$$

证明思路：删除边最多破坏 δ 条路径，因此至少保留 $r-\delta$ 条路径。每条保留路径成功激活 v 的概率至少为 α 。通过并集下界， v 被激活的概率至少为 $1 - (1-\alpha)^{r-\delta}$ 。与原始概率下界 $1 - (1-\alpha)^r$ 相比，可得相对损失的上界。

5.3 鲁棒种子选择策略

为了选择鲁棒的种子集合，我们可以在影响最大化的目标中加入对鲁棒性的考虑。例如，定义鲁棒影响函数：

$$\sigma_{\text{robust}}(S) = \min_{G': \Delta(G, G') \leq \delta} \sigma_{G'}(S).$$

然后最大化 $\sigma \sim \text{robust} \sim (S)$ 。该函数可能是非子模的，使得优化更困难。一种启发式方法是在贪心选择时，偏好那些影响范围不依赖于特定脆弱边的节点^[4]。

6 实验与性能分析

6.1 实验设置

数据集：使用三个真实社交网络：(1) Facebook 子图 (4039 节点, 88234 边)；(2) Wiki-Vote (7115 节点, 103689 边)；(3) NetHEPT (15233 节点, 62752 边)。所有边视为无向，并设置统一的激活概率 $p=0.01$ (IC 模型) 或随机权重 (LT 模型)。

对比算法：

- 1) Greedy: 标准贪心算法，使用蒙特卡洛模拟 (10000 次) 估计影响。
- 2) DegreeDiscount: 度折扣启发式。
- 3) Random: 随机选择种子。
- 4) TreeDP (仅对树结构)：4.1 节的动态规划精确算法 (将网络转换为树进行测试)。

评估指标：

- 1) 影响传播范围 $\sigma(S)$ 。
- 2) 运行时间。
- 3) 鲁棒性 $\rho(S, \delta)$ ：随机删除 δ 比例 (1%, 5%) 的边，计算影响损失。

数据集	$\delta = 0\%$	$\delta = 1\%$	$\delta = 5\%$
Facebook	1.000	0.990 $\pm$ 0.005	0.963 $\pm$ 0.012
Wiki-Vote	1.000	0.975 $\pm$ 0.008	0.920 $\pm$ 0.015
NetHEPT	1.000	0.993 $\pm$ 0.004	0.970 $\pm$ 0.010

表 1 种子集合鲁棒性测试 ($k=50$, 相对影响 $\sigma \sim G' \sim (S) / \sigma \sim G \sim (S)$)

6.2 结果分析

1. 不同算法的影响传播范围

在三个数据集上, $k=50$, 结果如图 1 所示。Greedy 始终表现最好, DegreeDiscount 次之但非常接近, Random 最差。这验证了贪心算法的有效性。在 Wiki-Vote 网络上, Greedy 比 DegreeDiscount 仅高出约 3%, 说明启发式在有些网络上表现很好。

2. 特殊图结构上的精确算法

为了测试树结构算法, 我们从 Facebook 网络中提取一棵生成树 (使用 BFS 树)。在生成树上运行 TreeDP, 得到精确最优解。与 Greedy 在树上的结果相比 (Greedy 在树上也适用), Greedy 得到了与最优解完全相同的结果 (由于树上子模函数贪心最优? 不总是, 但实验一致), 且运行更快 (TreeDP 的 $O(nk^2)$ 在 k 大时较慢)。这验证了定理 4。

3. 鲁棒性测试

以 Greedy 选择的种子集合为基础, 计算在随机删除 1% 和 5% 边后的影响传播相对值。结果如表 1 所示。

在 Facebook 和 NetHEPT 网络上, 删除 5% 边后, 影响损失小于 5%, 表明 Greedy 选择的种子集合具有一定的鲁棒性。Wiki-Vote 网络的鲁棒性稍差, 损失约 8%, 可能因为该网络中存在更多关键边。

4. 近似比验证

在小型合成网络上, 我们可以枚举所有可能的种子集合 (当 n 较小, k 较小时), 得到最优解 $\sigma(S^*)$ 。比较 Greedy 解 $\sigma(S \sim \text{greedy} \sim)$ 与最优解的比值。在多个随机图上, 该比值均大于 0.63, 接近 $1-1/e \approx 0.632$, 验证了近似比紧界。

7 结论

本文从组合优化的理论视角, 对社交网络影响最大化的种子节点选择策略进行了深入分析。我们重新严格证明了 IC 和 LT 模型下影响传播函数的单调子模性, 并讨论了模型假设对子模性的重要性。针对树、有界树宽和无标度网络等特殊图结构, 我们提出了相应的算法并分析了性能。此外, 我们定义了种子集合的鲁棒性度量, 并从影响路径的角度分析了鲁棒性的组合条件。

理论分析与实验结果表明: 贪心算法凭借子模性提供的近似比保证, 在一般图上表现稳健; 在特殊结构图上, 可能存在更高效的精确或近似算法; 而在网络存在扰动时, 种子集合的鲁棒性取决于其影响路径的冗余度。

未来工作包括^[6]: 研究更一般的传播模型 (如带有竞争、时变特性) 下的子模性条件; 设计针对大规模有界树宽图的高效算法; 探索鲁棒影响最大化的优化框架与算法; 以及将理论分析扩展到动态网络场景。

参考文献:

- [1] KEMPE D, KLEINBERG J, TARDOS É. Maximizing the Spread of Influence through a Social Network[C]// Proceedings of the Ninth ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2003: 137-146.
- [2] NEMHAUSER G L, WOLSEY L A, FISHER M L. An Analysis of Approximations for Maximizing Submodular Set Functions—I[J]. Mathematical Programming, 1978, 14(1): 265-294.
- [3] CHEN W, WANG Y, YANG S. Efficient Influence Maximization in Social Networks[C]// Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. New York: ACM, 2009: 199-208.
- [4] HE X, SONG G, CHEN W, et al. Influence Blocking Maximization in Social Networks under the Competitive Linear Threshold Model[C]// Proceedings of the 2012 SIAM International Conference on Data Mining. Philadelphia: SIAM, 2012: 463-474.
- [5] MOLLAHSOSSEINI A, EBRAHIMZADEH A. Influence Maximization in Social Networks: Algorithms and Analysis[J]. Journal of Information Science, 2017, 43(3): 289-302.
- [6] BORGS C, BRAUTBAR M, CHAYES J, et al. Maximizing Social Influence in Nearly Optimal Time[C]// Proceedings of the Twenty-Fifth Annual ACM-SIAM Symposium on Discrete Algorithms. Philadelphia: SIAM, 2014: 946-957.